

SVEUČILIŠTE U ZAGREBU  
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 1378

**PRIMJENA NEURONSKIH MREŽA S KOMPLEKSNIM  
VRIJEDNOSTIMA U KLASIFIKACIJI RADARSKIH SIGNALA**

Petar Zlomislić

Zagreb, lipanj 2024.

SVEUČILIŠTE U ZAGREBU  
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 1378

**PRIMJENA NEURONSKIH MREŽA S KOMPLEKSNIM  
VRIJEDNOSTIMA U KLASIFIKACIJI RADARSKIH SIGNALA**

Petar Zlomislić

Zagreb, lipanj 2024.

## ZAVRŠNI ZADATAK br. 1378

Pristupnik: **Petar Zlomislić (0036542372)**

Studij: Elektrotehnika i informacijska tehnologija i Računarstvo

Modul: Računarstvo

Mentor: izv. prof. dr. sc. Marko Bosiljevac

Zadatak: **Primjena neuronskih mreža s kompleksnim vrijednostima u klasifikaciji radarskih signala**

### Opis zadatka:

Razni radarski sustavi danas se intenzivno primjenjuju u različitim područjima industrije i medicine za klasifikaciju objekata, detekciju značajki ili neki drugi oblik automatizirane obrade. Pritom se u klasičnom pristupu klasifikaciji primjenom modela dubokog učenja tipično koriste samo amplitudne vrijednosti signala, a informacija o fazi ostaje neiskorištena. Neuronske mreže s kompleksnim vrijednostima (eng. Complex Valued Neural Networks - CVNN) zbog toga predstavljaju unaprijeđeni pristup rješavanju ovakvih problema jer mogu iskoristiti cjelovit radarski amplitudno-fazni signal zapisan u obliku kompleksnih brojeva i time potencijalno povećati točnost klasifikacije. U ovom završnom radu potrebno je dati pregled metodologija koje se koriste u klasifikaciji radarskih signala te objasniti osnovne principe neuronskih mreža s naglaskom na CVNN. Implementirati odabrani CVNN model te ga iskoristiti za klasifikaciju dostupnih laboratorijskih radarskih podataka dobivenih radarom s kontinuirano frekvencijski moduliranim signalom. Analizirati točnost klasifikacije i usporediti dobivene rezultate s rezultatima implementiranih modela koji koriste samo amplitudnu informaciju.

Rok za predaju rada: 14. lipnja 2024.



## Sadržaj

UVOD.....	3
1. Princip radarskog snimanja .....	4
1.1 Radar sa sintetičkom aperturom .....	4
1.2. Korišteni radarski podatci.....	6
2. Neuronske mreže .....	11
2.1. Konvolucijska mreža .....	11
2.2. Kompleksne neuronske mreže.....	13
2.2.1. Aktivacijske funkcije .....	14
2.2.2. Treniranje kompleksnih neuronskih mreža .....	15
2.2.3. Slojevi kompleksne konvolucijske neuronske mreže .....	15
3. Rezultati.....	17
3.1. Točnost .....	17
3.2. Konfuzijske matrice.....	24
4. Zaključak .....	31
5. Literatura .....	32


# UVOD

Razni radarski sustavi danas se intenzivno primjenjuju u različitim područjima industrije i medicine za klasifikaciju objekata, detekciju značajki ili neki drugi oblik automatizirane obrade. Pritom se u klasičnom pristupu klasifikaciji primjenom modela dubokog učenja tipično koriste samo amplitudne vrijednosti signala, a informacija o fazi ostaje neiskorištena. Neuronske mreže s kompleksnim vrijednostima (eng. Complex Valued Neural Networks – CVNN) zbog toga predstavljaju unaprijeđeni pristup rješavanju ovakvih problema jer mogu iskoristiti cjelovit radarski amplitudno-fazni signal zapisan u obliku kompleksnih brojeva i time potencijalno povećati točnost klasifikacije. U ovom radu ćemo prvo opisati rad SAR radara i proces generiranja slika iz njega, zatim ćemo objasniti osnovne principe neuronskih mreža s posebnim naglaskom na specifičnosti koje se javljaju s korištenjem kompleksnih vrijednosti u neuronima. Na kraju ćemo analizirati rezultate treniranja CVNN-a i mreže s realnim podacima te ćemo usporediti točnost klasifikacije tih dviju mreža.

# 1. Princip radarskog snimanja


## 1.1 Radar sa sintetičkom aperturom

Za generiranje podataka koje smo koristili za treniranje mreža koristili smo radar sa sintetičkom aperturom (eng. Synthetic Aperture Radar – SAR) čiji je način rada prikazan na Slici 1. Taj tip radara koristimo za generiranje dvodimenzionalnih slika prostora koji se nalazi ispred radara. On funkcionira tako da se radar pomjera po jednoj osi te šalje pulseve svaki put kada promjeni lokaciju. Tako nastaje niz mjerenja koji kada se spoje daju informaciju o čitavom prostoru ispred radara.



Slika 1: Prikaz SAR-a koji se kreće po x osi iz [1]

Svaki puls se generira na način da stvara val s rastućom frekvencijom za vrijeme pulsa kako je prikazano u Slici 2. Kako bi uz pomoć radara stvorili sliku prostora ispred radara potrebno je odrediti udaljenosti objekata od radara. Pošto znamo da elektromagnetski valovi putuju brzinom svjetlosti za određivanje udaljenosti dovoljno je odrediti koliko vremena je val putovao. Val, nakon što je poslan iz antene, odbija se od objekt i dolazi do promjene u amplitudi i frekvenciji vala. Te promjene se događaju zbog fizičkih svojstava objekta od kojeg se val odbio – njegovog oblika, materijala od kojeg je napravljen itd.



Slika 2: Prikaz vala koji šalje radar i vala koji se odbija od objekt.


Nakon odbijanja val se vraća na drugu antenu radara te počinje proces obrade signala. U tom procesu množenjem signala miješaju se originalni poslani signal i signal koji se odbio kasnije. Filtriranjem i daljom obradom tog „miješanog“ signala dobivamo udaljenosti radara i objekta i samim time radarsku sliku objekta. Te slike se kasnije mogu koristiti kao ulazni podatci za neuronske mreže u problemima klasifikacije. Slika 2 i opisani princip radara opisuju radar s kontinuiranom frekvencijskom modulacijom [4] (eng. Frequency Modulated Continuous Wave - FMCW) koji se najčešće koristi u kombinaciji sa SAR principom snimanja

Drugi pristup treniranju neuronskih mreža na radarskim podacima je pristup u kojem uzimamo signal koji dobivamo odmah nakon miješanja. Slike na kojima su objekti jasno vidljivi nastale su za ljudsku upotrebu i nakon obrade početnog signala iz kojega su one nastale dio informacija se gubi, ali ta informacija može pomoći neuronskoj mreži u procesu klasifikacije.

Punu informaciju o objektu ispred radara dat će nam tek takozvani IQ signal. To je kompleksni signal koji se sastoji od dvije komponente I ili In-phase i Q ili Quadrature. I



komponenta nastaje miješanjem odbijenog signala i početnog signala, a Q komponenta miješanjem obijenog signala i početnog signala koji je ovaj put pomaknut za  $90^\circ$ . Te dvije komponente se onda zbrajaju jedna s drugom.[4] Ovakav signal nam nosi informaciju o amplitudi i fazi svakog odbijenog vala i njega ćemo koristiti za treniranje neuronske mreže.



Slika 3: Prikaz vala s IQ komponentama

## 1.2. Korišteni radarski podatci

U svrhu ove analize koristili smo bazu mjerenja s tri različita materijala objekta i dva različita oblika objekta.


Vrste materijala su:

- aluminij
- plastika
- staklo


Vrste oblika su:

- okrugli
- kvadratni


U slikama 4-9 slijede primjeri neobrađenih mjerenja amplitude i faze za svaku od kombinacija klasa:




Slika 4: Amplituda i faza valova odbijenih od aluminijskog okruglog objekta



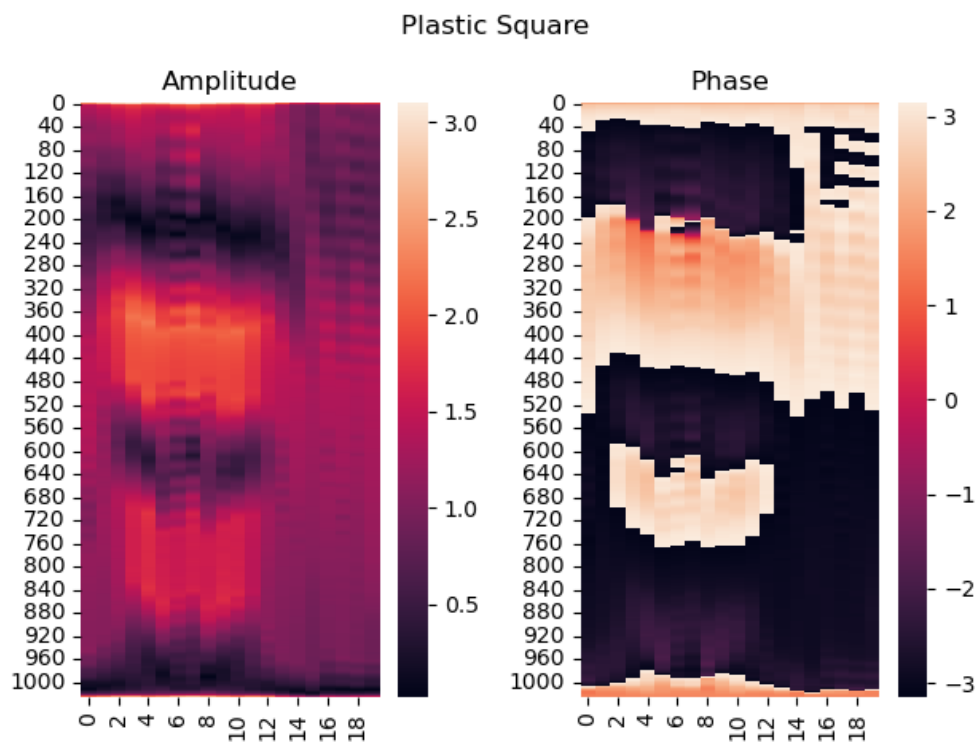
Slika 5: Amplituda i faza valova odbijenih od aluminijskog kvadratnog objekta




Slika 6: Amplituda i faza valova odbijenih od staklenog okruglog objekta



Slika 7: Amplituda i faza valova odbijenih od staklenog kvadratniog objekta



Slika 8: Amplituda i faza valova odbijenih od plastičnog kvadratnog objekta



Slika 9: Amplituda i faza valova odbijenih od plastičnog okruglog objekta

X os na slici predstavlja jedno mjerenje za svaki pomak radara, a na y osi je vremenski uzorak signala (koji je diskretiziran sa 1024 uzoraka). Vrijednosti svake ćelije na lijevoj

djelu predstavljaju vrijednost amplitude, a na desnom vrijednost faze u radijanima. Svaka od ovih 6 klasa ima 50 slika što sveukupno čini bazu od ukupno 300 slika.

## 2. Neuronske mreže

Za analiziranje ovih slika koristit ćemo umjetne neuronske mreže i algoritme dubokog učenja. Duboko učenje je grana strojnog učenja temeljena na umjetnim neuronskim mrežama. Umjetna neuronska mreža koristi slojeve međusobno povezanih neurona za obradu i učenje iz ulaznih podataka. Svaka neuronska mreža se razlikuje brojem neurona u svakom sloju i načinu na koji su ti neuroni povezni. Ta kombinacija broja neurona i načina na koji su povezani naziva se arhitektura umjetne neuronske mreže.

U standardnom pristupu dubokog učenja svaki neuron ima svoju vrijednost prikazanu s realnim brojem, a sve veze između neurona također imaju realni broj asociran s njima. Mrežu treniramo algoritmom propagacije pogreške unatrag. Ulazni podatak prolazi kroz čitavu mrežu i transformira se u izlaznu vrijednost. Na temelju ove izlazne vrijednosti algoritam računa vrijednost „cost“ funkcije, a vrijednost te funkcije koristi kako bi promijenio vrijednosti neurona i veza među neuronima korištenjem metode gradijentnog spusta. Rezultat ovog algoritma je neuronska mreža s minimalnom vrijednosti „cost“ funkcije i samim time najmanjom greškom kod željene funkcije neuronske mreže.

Čest problem koji nastaje u procesu treniranja neuronskih mreža je problem prenaučivosti. Taj problem se javlja kada mreža predobro nauči podatke koje smo joj dali u treniranju i ne uspijeva generalizirati na podacima s kojima se može kasnije susretati. Jedan od načina za sprječavanje prenaučivosti je razdvajanje seta podataka za treniranje na dva seta: jedan na kojem ćemo trenirati mrežu i jedan na kojem ćemo testirati mrežu. Ocjenu rezultata mreže radimo na setu za testiranje.

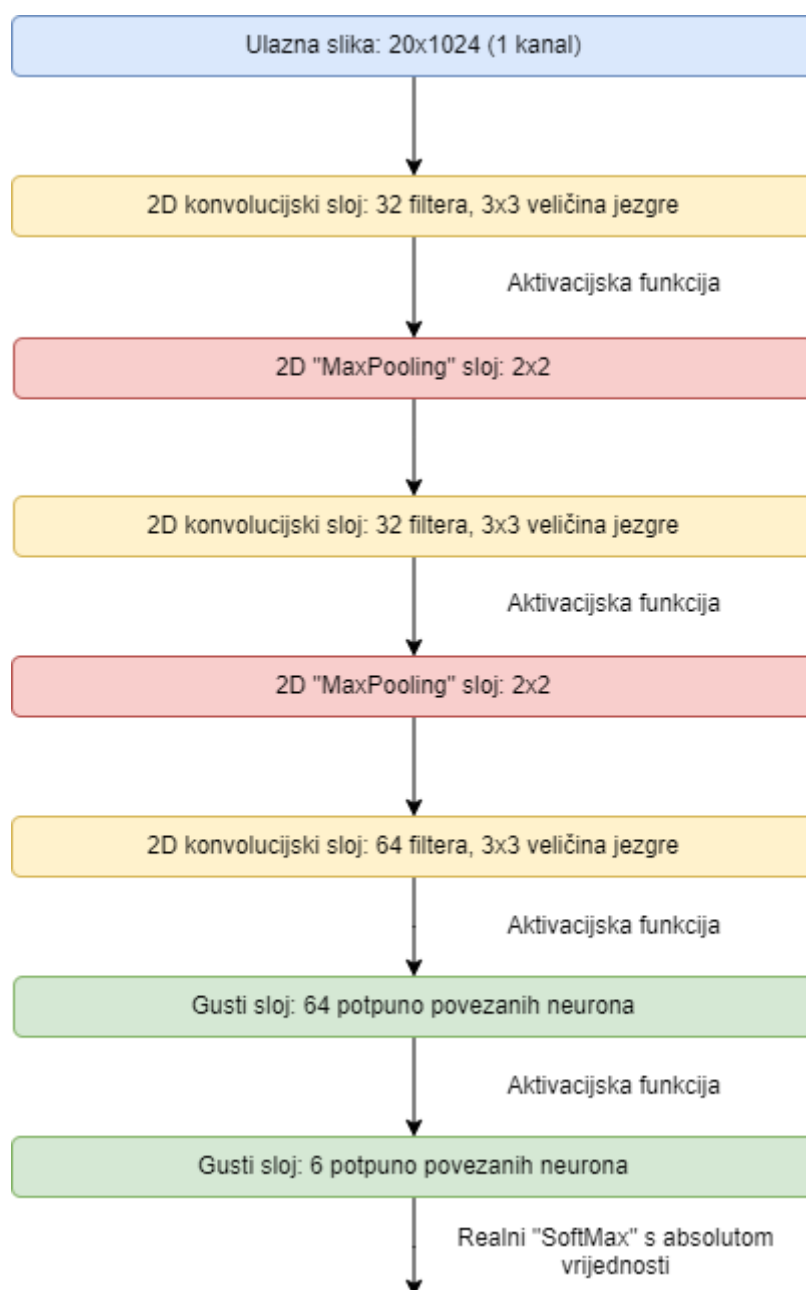
### 2.1. Konvolucijska mreža

Konvolucijska neuronska mreža je vrsta umjetne neuronske mreže koja se sastoji od konvolucijskih slojeva. Konvolucijski sloj se sastoji od više filtera ili kernela. Filter je matrica manje dimenzije od ulaznih podataka koja se primjenjuje na ulazni podatak tako da se vrijednosti ulaznog podatka zbrajaju ali težinski s vrijednostima matrice. Procesom treniranja ovi filteri uče prepoznati značajke u ulaznom podatku koje su relevantne za zadatak koji želimo da mreža može obaviti.

Bitan sloj u arhitekturi konvolucijske mreže je i „pooling“ sloj. To je sloj koji smanjuje dimenzije podataka. Taj sloj tipično dolazi iza jednog ili više konvolucijskih slojeva.

Zbog ovakve arhitekture konvolucijske neuronske mreže su jako efikasne kada rade s dvodimenzionalnim podacima kao što su slike i primjenu nalaze, između ostaloga, u sustavima za prepoznavanje slika i videa, sustavima za klasifikaciju slika, sustavima za detekciju objekata na slikama, analizi medicinskih slika, analizi i procesiranju prirodnog jezika itd.

Arhitektura konvolucijske mreže koju ćemo mi koristiti u ovom radu je sljedeća:



Slika 10: Arhitektura jedne od kompleksnih mreža koje ćemo koristiti. Ostale se razlikuju samo u tipu aktivacijske funkcije

## 2.2. Kompleksne neuronske mreže

Umjesto mreža s realnim vrijednostima za problem klasifikacije podataka koje smo dobili s našim radarom trebamo koristiti neuronsku mrežu s kompleksnim vrijednostima. Promjena tipa podataka iz realnih u kompleksne nosi sa sobom niz problema s matematičke strane jer su matematičke operacije, kao npr. matrično množenje, derivacija „cost“ funkcije i



aktivacijske funkcije, koje koristimo u neuronskim mrežama originalno definirane za realne brojeve.

Još jedan problem koji se javlja je rast računalne kompleksnosti u kompleksnim modelima. Na primjer operacija kompleksnog množenja sadrži četiri operacije realnog množenja i tri operacije realnog zbrajanja. Posljedica toga je da za dvije neuronske mreže s istom arhitekturom od kojih je jedna realna, a jedna kompleksna proces treniranja kompleksne mreže će uvijek trajati duže. Ova činjenica predstavlja bitan kompromis između točnosti mreže i vremena treniranja mreže kada biramo hoćemo li koristiti realne ili kompleksne mreže.

### 2.2.1. Aktivacijske funkcije

Aktivacijske funkcije uvode nelinearnosti kod transformacija podataka koje provode neuronske mreže. Glavni problem kod definiranja kompleksnih aktivacijskih funkcija je problem diferencijabilnosti. Holomorfna funkcija je funkcija koju je moguće kompleksno derivirati u svim točkama njene domene. Važan rezultat kompleksne analize je Liouvilleov teorem koji govori da su sve omeđene holomorfne funkcije konstantne. Što znači da nije moguće definirati kompleksnu aktivacijsku funkciju koja je holomorfna i koja „gnječi“ prostor, a takve aktivacijske funkcije se najčešće koriste kod realnih aktivacijskih funkcija. Postoji više pristupa rješavanju ovog problema i svaki od njih definira jednu klasu aktivacijskih funkcija. [2]

Jedan od prvih pristupa je pristup fazorskim funkcijama. Pristup je razvijen na temelju MVN-ova (eng. Multi Value Neuron). Ovakve funkcije čitav kompleksni prostor transformiraju u jediničnu kružnicu. Jedna takva aktivacijska funkcija je (1)

$$f(z) = \frac{z}{|z|} \quad (1)$$

Drugi pristup govori da je holomorfnosti previše strog te da je dovoljno da aktivacijske funkcije budu diferencijabilne u odnosu na njihove realne i imaginarne komponente. Takve funkcije nazivamo podijeljene aktivacijske funkcije. One dolaze u dva tipa: tip A i tip B. Funkcije tipa A su funkcije koje su definirane na kartezijskom zapisu kompleksnog broja, a funkcije tipa B su funkcije koje su definirane na polarnom zapisu kompleksnog broja.

One fazu ostavljaju netaknutom, a smanjuju amplitudu. U ovom radu ćemo koristiti funkcije oba tipa. [2]

Od ostalih tipova postoji klasa funkcija temeljena na ReLU aktivacijskoj funkciji.

Od funkcija tipa A koristit ćemo kartezijsku ReLU funkciju (2).

$$f(x + jy) = \max(x, 0) + j\max(y, 0) \quad (2)$$

Od funkcija tipa B koristit ćemo skaliranu eksponencijalnu linearnu aktivacijsku jedinicu (3).

$$f(Ae^{bj}) = s * \text{elu}(A, \alpha) * e^{bj} \quad (3)$$

gdje je:

$$\text{elu}(x, \alpha) = \begin{cases} x, & x > 0 \\ \alpha(e^x - 1), & x \leq 0 \end{cases} \quad (4)$$

### 2.2.2. Treniranje kompleksnih neuronskih mreža

Treniranje neuronske mreže se odnosi na proces ugađanja vrijednosti težina u mreži kako bi postigli minimalnu vrijednost „cost“ funkcije. Postupak koji koristimo kako bi postigli tu minimizaciju nazivamo gradijentni spust i propagacija pogreške unatrag.

Algoritam funkcionira tako da prvo izračunamo pogreške za posljednji sloj. Zatim za svaki sloj prije njega moramo korigirati vrijednosti težina kako bi smanjili grešku u posljednjem sloju. Veličinu korigacije dobivamo derivacijom pogrešaka na zadnjem sloju. Zbog toga nam je važno da sve komponente mreže budu diferencijabilne. [3]

### 2.2.3. Slojevi kompleksne konvolucijske neuronske mreže

Slojevi neuronske mreže predstavljaju matematičke operacije koje mreža obavlja nad ulaznim podacima. Neki od često korištenih slojeva mogu se jednostavno prebaciti u kompleksnu domenu, dok neke nije tako jednostavno prebaciti.

U mreži koju smo koristili u ovom radu imamo konvolucijske, „max pooling“, i „dense“ slojeve. Konvolucijski sloj obavlja operaciju konvolucije s filterom. Ta operacija se sastoji samo od množenja i zbrajanja pa ju je trivijalno prebaciti u kompleksnu domenu. Isto vrijedi i za „dense“ sloj.

„Max pooling“ sloj je teže definirati jer nad kompleksnim brojevima nisu definirane operacije veći i manji koje su nam potrebne kako bi našli najveći od nekoliko kompleksnih brojeva. Jedan od načina za riješiti ovaj problem je uzeti maksimum od samo jednog od komponenata kompleksnog broja. Ovdje ćemo koristiti „max pooling“ algoritam koji uzima kompleksni broj s maksimalnom vrijednosti amplitude. [3]

## 3. Rezultati


Trenirat ćemo 4 različite mreže. Jedna od njih će biti realna konvolucijska mreža. Ostale tri će biti kompleksne konvolucijske mreže s tri različita tipa aktivacijskih funkcija kako smo definirali ranije u radu.

Sve od tih mreža treniramo da klasificiraju podatke na tri različita načina – da klasificiraju materijal i oblik zajedno (6 klasa), da klasificiraju samo materijal (3 klase) i samo oblik (2 klase).


Sve mreže su trenirane na 50 epoha.

### 3.1. Točnost


Točnost mreže definiramo kao omjer broja podataka koje je mreža ispravno klasificirala i broja svih podataka. Na sljedećim slikama (11-22) prikazana je točnost klasifikacije za različite slučajeve u ovisnosti o epohama treniranja. Sumarni rezultati točnosti za sve slučajeve prikazani su u Tablici 1.




Slika 11: Točnost realne konvolucijske mreže u klasificiranju oblika: val\_accuracy u zadnjoj epohi: 0.9667, vrijeme treniranja u sekundama: 92.660027




Slika 12: Točnost realne konvolucijske mreže u klasificiranju materijala: val\_accuracy u zadnjoj epohi: 0.8667, vrijeme treniranja u sekundama: 93.5655697




Slika 13: Točnost realne konvolucijske mreže u klasificiranju materijala i oblika: val\_accuracy u zadnjoj epohi: 0.8333, vrijeme treniranja u sekundama: 204.4428292




Slika 14: Točnost kompleksne konvolucijske mreže u klasificiranju oblika s aktivacijskom funkcijom tipa A: val\_accuracy u zadnjoj epohi: 0.9167, vrijeme treniranja u sekundama: 459.4184901




Slika 15: Točnost kompleksne konvolucijske mreže u klasificiranju materijala s aktivacijskom funkcijom tipa A: val\_accuracy u zadnjoj epohi: 0.9167, vrijeme treniranja u sekundama: 457.243126




Slika 16: Točnost kompleksne konvolucijske mreže u klasificiranju materijala i oblika s aktivacijskom funkcijom tipa A: val\_accuracy u zadnjoj epohi: 0.8833, vrijeme treniranja u sekundama: 459.332226



Slika 17: Točnost kompleksne konvolucijske mreže u klasificiranju oblika s aktivacijskom funkcijom tipa B: val\_accuracy u zadnjoj epohi: 0.9667, vrijeme treniranja u sekundama: 656.4533




Slika 18: Točnost kompleksne konvolucijske mreže u klasificiranju materijala s aktivacijskom funkcijom tipa B: val\_accuracy u zadnjoj epohi: 0.9333, vrijeme treniranja u sekundama: 646.465




Slika 19: Točnost kompleksne konvolucijske mreže u klasificiranju materijala i oblika s aktivacijskom funkcijom tipa B: val\_accuracy u zadnjoj epohi: 0.7833, vrijeme treniranja u sekundama: 647.5240122






Slika 20: Točnost kompleksne konvolucijske mreže u klasificiranju oblika s fazorskom aktivacijskom funkcijom: val\_accuracy u zadnjoj epohi: 0.9833, vrijeme treniranja u sekundama: 615.822799



Slika 21: Točnost kompleksne konvolucijske mreže u klasificiranju materijala s fazorskom aktivacijskom funkcijom: val\_accuracy u zadnjoj epohi: 0.9167, vrijeme treniranja u sekundama: 627.1246



Slika 22: Točnost kompleksne konvolucijske mreže u klasificiranju materijala i oblika s fazorskom aktivacijskom funkcijom: val\_accuracy u zadnjoj epohi: 0.8667, vrijeme treniranja u sekundama: 600.3847

	Oblik	Materijal	Oblik i materijal
<b>Realna mreža</b>	0.9667	0.8667	0.8333
<b>Kompleksna mreža (tip A)</b>	0.9167	0.9167	0.8833
<b>Kompleksna mreža (tip B)</b>	0.9667	0.9333	0.7833
<b>Kompleksna mreža (fazorska a.f.)</b>	0.9833	0.9167	0.8667

Tablica 1: Tablica koja prikazuje točnost mreže nad setom za testiranje na kraju 50. epohe


U Tablici 1 se nalaze točnosti svake od mreža u sva tri slučaja na koje smo podijelili set podataka. U samo 2 od 12 slučajeva neuronska mreža sa kompleksnim vrijednostima nije postigla bolji ili jednak rezultat kao i realna mreža. Najgori rezultat od 78% postigla je kompleksna mreža sa aktivacijskom funkcijom tipa B trenirana da klasificira oblik i materijal objekta, a najbolji rezultat od 98% postigla je kompleksna mreža sa fazorskom

aktivacijskom funkcijom trenirana da klasificira samo oblik objekta. Vrijeme treniranja svake od kompleksnih mreža je bilo 4 do 6 puta dulje od realne mreže.


Kako vidimo kompleksne mreže bolje održavaju točnost čak i ako količina podataka nad kojim ih treniramo pada te ih zbog toga ima smisla koristiti u takvim uvjetima dok god mislimo o kompromisu između točnosti i vremena treniranja

## 3.2. Konfuzijske matrice


Konfuzijska matrica je osnovni način prikaza performansi klasifikacijskih modela. Sastoji se od kvadratne matrice gdje x os predstavlja predviđene klase iz modela te y os predstavlja stvarne klase podataka. Na dijagonali matrice stoje vrijednosti koje je mreža dobro klasificirala, a u ostatku matrice pogreške u klasifikaciji. Konfuzijske matrice za analizirane primjere prikazane su na slikama 23-34.




Slika 23: Konfuzijska matrica za realnu konvolucijsku mrežu u klasificiranju oblika




Slika 24: Konfuzijska matrica za realnu konvolucijsku mrežu u klasificiranju materijala




Slika 25: Konfuzijska matrica za realnu konvolucijsku mrežu u klasificiranju oblika i materijala




Slika 26: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa A u klasificiranju oblika




Slika 27: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa A u klasificiranju materijala




Slika 28: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa A u klasificiranju oblika i materijala




Slika 29: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa B u klasificiranju oblika



Slika 30: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa B u klasificiranju materijala




Slika 31: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s aktivacijskom funkcijom tipa B u klasificiranju materijala i oblika




Slika 32: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s fazorskom aktivacijskom funkcijom u klasificiranju oblika





Slika 33: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s fazorskom aktivacijskom funkcijom u klasificiranju materijala



Slika 34: Konfuzijska matrica za kompleksnu konvolucijsku mrežu s fazorskom aktivacijskom funkcijom u klasificiranju oblika i materijala

## 4. Zaključak

Cilj rada je bio ispitati razlike u performansama neuronskih mreža sa realnim i sa kompleksnim vrijednostima kod problema klasifikacije radarskih slika. Kako bi smo ispitali te performanse implementirali smo 4 različite mreže. Jednu realnu i tri kompleksne sa različitim tipovima aktivacijskih funkcija. Prikazali smo točnosti tih mreža te konfuzijske matrice na tri različita slučaja.

Rezultati nas jasno vode do zaključka da kompleksne neuronske mreže mogu postići veću točnost nego realne neuronske mreže. U svim slučajevima osim u jednom je kompleksna mreža došla do veće mjere točnosti. Ovakvi rezultati sugeriraju da kompleksne neuronske mreže imaju veći kapacitet za učenje podataka gdje mogu koristiti podatke iz kompleksne domene.

Međutim, jedan značajan nedostatak kompleksnih neuronskih mreža je vrijeme potrebno za njihovo treniranje. Ono, ovisno o tipu aktivacijske funkcije, može biti i 4 do 6 puta veće od realne neuronske mreže.

U konačnici, izbor između ovih dvaju tipova neuronski mreža trebao bi biti vođen specifičnim zahtjevima aplikacije. Dok su kompleksne mreže superiorne u smislu performanci, realne mreže mogu biti preferirane kada je vrijeme treniranja kritičan faktor pogotovo u puno većim mrežama gdje se razlika u vremenu treniranja puno više osjeti.

## 5. Literatura

- [1] Kelsey Herndon, Franz Meyer, Africa Flores, Emil Cherrington i Leah Kucera, What is Synthetic Aperture Radar?, NASA. Poveznica: <https://www.earthdata.nasa.gov/learn/backgrounders/what-is-sar>, pristupljeno 7.6.2024.
- [2] Bassey J., LI X., Qian L., *A Survey of Complex-Valued Neural Networks*, arXiv:2101.12249 (2021)
- [3] J. A. Barrachina, C. Ren, G. Vieillard, C. Morisseau i J.-P. Ovarlez, *Theory and implementation of complex-valued neural networks*, arXiv:2302.08286
- [4] Gregory Charvat, *Small and Short-Range Radar Systems (Modern and Practical Approaches to Electrical Engineering)* 1st Edition, CRC Press, 2014

# Primjena neuronskih mreža s kompleksnim vrijednostima u klasifikaciji radarskih signala

## Sažetak

Cilj ovog rada je razvoj klasifikacijskog modela za analizu radarskih podataka koji koristi neuronske mreže s kompleksnim vrijednostima. U uvodnom dijelu rada opisan je rad radara sa sintetičkom aperturom te načina na koji on generira podatke. Takve podatke smo koristili u daljnjoj analizi te su primjeri podataka prikazani u radu. Također, u uvodnom dijelu je objašnjen rad neuronskih mreža koje su se koristile za analizu radarskih podataka, te su predstavljeni problemi koji nastaju kod razvoja neuronskih mreža s kompleksnim vrijednostima. Prikazani su pristupi rješavanju spomenutih problema te implementacija klasifikacije radarskih podataka primjenom četiri različita pristupa. Primjenom razvijenih algoritama pokazano je da je moguće ostvariti veću točnost klasifikacije primjenom neuronskih mreža s kompleksnim vrijednostima čime je potvrđena opravdanost ovakvog pristupa u analizi kompleksnih radarskih signala i slika.

## Ključne riječi

GBSAR, radar sa sintetičkom aperturom, neuronske mreže, neuronske mreže s kompleksnim vrijednostima

# Application of complex valued neural networks in the classification of radar signals

## Summary

The goal of this work was to develop a classification model for radar data analysis that uses complex valued neural networks. The introductory part of the paper describes the operation of the synthetic aperture radar and the way it generates data. We used such data in further analysis, and examples of considered radar data are presented in the paper. Also, in the introductory part, the principles of neural networks that were used for radar data analysis is explained, and the problems that arise in the development of complex valued neural networks are presented. Approaches to solving the mentioned problems and the implementation of classification of radar data using four different approaches are presented. By applying the developed algorithms, it was shown that it is possible to achieve higher classification accuracy by applying complex valued neural networks, which confirms the justification of this approach in the analysis of complex radar signals and images.

## Ključne riječi

GBSAR, synthetic aperture radar, neural networks, complex valued neural networks